



Московский  
Авиационный  
Институт

# Методы оптимизации

# Поиск безусловного экстремума

Кафедра 806

Выполнили студенты группы  
М8О-308Б-21:

Ползикова Алина  
Белоносов Кирилл  
Шевлякова София

Москва 2024

# Постановка задачи

Найти безусловный экстремум:

$$f(x) = a\left(x_1 - \left[\frac{n}{2}\right]\right)^2 + b(x_2 - m)^2$$

- а) с помощью необходимых и достаточных условий;
- б) методом градиентного спуска с постоянным шагом;
- в) методом Полака-Рибьера;
- г) методом Ньютона-Рафсона;

# Аналитическое решение

Найти безусловный экстремум с помощью необходимых и достаточных условий

$$f(x) = a\left(x_1 - \left[\frac{n}{2}\right]\right)^2 + b(x_2 - m)^2$$

1. Проверим необходимое условие экстремума первого порядка:  $\text{grad } f(x) = 0$

$$\frac{df(x)}{dx_1} = 2a\left(x_1 - \left[\frac{n}{2}\right]\right)$$

$$\frac{df(x)}{dx_2} = 2b(x_2 - m)$$

$$\text{grad } f(x) = \begin{pmatrix} 2a\left(x_1 - \left[\frac{n}{2}\right]\right) \\ 2b(x_2 - m) \end{pmatrix}$$

	m = 8 n = 3	m = 8 n = 17	m = 8 n = 28
x*	(1, 8)	(8, 8)	(14, 8)

# Аналитическое решение

1. Проверим достаточное условие экстремума первого порядка:

Матрица Гессе 
$$H(x) = \begin{pmatrix} 2a & 0 \\ 0 & 2b \end{pmatrix}$$

- Если  $a > 0$  и  $b > 0$ , то  $H(x) > 0$  достаточное условие экстремума первого порядка выполняется –  $x^*$  точка минимума  $f(x^*) = 0$
- Если  $a < 0$  и  $b < 0$ , то  $H(x) < 0$  достаточное условие экстремума первого порядка выполняется –  $x^*$  точка максимума  $f(x^*) = 0$
- Если  $a < 0$  и  $b > 0$  или  $a > 0$  и  $b < 0$  – нет экстремума
- При остальных значениях  $a$  и  $b$  достаточное условие экстремума первого порядка не выполняется, значит надо проверить необходимое условие экстремума второго порядка

# Аналитическое решение

3. Проверим необходимое условие экстремума второго порядка:

- Если  $a = 0$  и  $b > 0$ , то  $H(x) \geq 0$  –  $x^*$  может быть локальным минимумом, требуется дополнительное исследование
- Если  $a = 0$  и  $b < 0$ , то  $H(x) \leq 0$  –  $x^*$  может быть локальным максимумом, требуется дополнительное исследование
- Если  $a > 0$  и  $b = 0$ , то  $H(x) \geq 0$  –  $x^*$  может быть локальным минимумом, требуется дополнительное исследование
- Если  $a < 0$  и  $b = 0$ , то  $H(x) \leq 0$  –  $x^*$  может быть локальным максимумом, требуется дополнительное исследование
- Если  $a = 0$  и  $b = 0$ , то  $H(x) = 0$  – требуется дополнительное исследование

# Метод градиентного спуска с постоянным шагом

## Алгоритм

*Шаг 1.* Задать  $x^0$ ,  $0 < \varepsilon < 1$ ,  $\varepsilon_1 > 0$ ,  $\varepsilon_2 > 0$ ,  $M$  – предельное число итераций.

Найти градиент функции в произвольной точке  $\nabla f(x) = \left( \frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$ .

*Шаг 2.* Положить  $k = 0$ .

*Шаг 3.* Вычислить  $\nabla f(x^k)$ .

*Шаг 4.* Проверить выполнение критерия окончания  $\|\nabla f(x^k)\| < \varepsilon_1$ :

- а) если критерий выполнен, расчет закончен,  $x^* = x^k$ ;
- б) если критерий не выполнен, то перейти к шагу 5.

# Метод градиентного спуска с постоянным шагом

Шаг 5. Проверить выполнение неравенства  $k \geq M$  :

- а) если неравенство выполнено, то расчет окончен:  $x^* = x^k$ ;
- б) если нет, то перейти к шагу 6.

Шаг 6. Задать величину шага  $t_k$ .

Шаг 7. Вычислить  $x^{k+1} = x^k - t_k \nabla f(x^k)$ .

Шаг 8. Проверить выполнение условия

$$f(x^{k+1}) - f(x^k) < 0 \quad (\text{или} \quad f(x^{k+1}) - f(x^k) < -\varepsilon \|\nabla f(x^k)\|^2) \underline{::}$$

- а) если условие выполнено, то перейти к шагу 9;
- б) если условие не выполнено, положить  $t_k = \frac{t_k}{2}$  и перейти к шагу 7.


Шаг 9. Проверить выполнение условий

$$\|x^{k+1} - x^k\| < \varepsilon_2, \quad |f(x^{k+1}) - f(x^k)| < \varepsilon_2:$$


- а) если оба условия выполнены при текущем значении  $k$  и  $k = k - 1$ , то расчет окончен,  $x^* = x^{k+1}$ ;
- б) если хотя бы одно из условий не выполнено, положить  $k = k + 1$  и перейти к шагу 3.

# Метод градиентного спуска с постоянным шагом


Gradient Descent (constant step) - 3D




Gradient Descent (constant step) - 3D




Gradient Descent (constant step) - 3D




Gradient Descent (constant step) - 2D



Gradient Descent (constant step) - 2D



Gradient Descent (constant step) - 2D



$x_0 = (10, 15)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 87$   
 $x^* = (1, 8.00006307)$

$x_0 = (-8, 8)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 12$   
 $x^* = (7.99999905, 8)$

$x_0 = (32, -8)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 93$   
 $x^* = (14, 7.99993531)$



# Метод Полака-Рибьера

Входные параметры:  $\mathbf{x}$  – начальная точка поиска,  $f(\mathbf{x})$  – процедура вычисления функции,  $\varepsilon$  – допустимая погрешность.


Выходной параметр  $\mathbf{x}$  – конечная точка поиска.

1. Вычислить  $\mathbf{g}_x = \nabla f(\mathbf{x})$  и положить  $\mathbf{d} = -\mathbf{g}_x$ .
2. Вычислить  $r = \arg \min_{\lambda} f(\mathbf{x} + \lambda \cdot \mathbf{d})$ ,  $\mathbf{s} = r \cdot \mathbf{d}$ .
3. Положить  $\mathbf{x} = \mathbf{x} + \mathbf{s}$ ,  $\mathbf{g}_y = \mathbf{g}_x$ .
4. Вычислить  $\mathbf{g}_x = \nabla f(\mathbf{x})$ ,  $\beta = \mathbf{g}_x^T \cdot (\mathbf{g}_x - \mathbf{g}_y) / (\mathbf{g}_y^T \cdot \mathbf{g}_y)$ .
5. Положить  $\mathbf{d} = -\mathbf{g}_x + \beta \cdot \mathbf{d}$ .
6. Если  $\|\mathbf{s}\| > \varepsilon$ , то перейти к шагу 2.
7. Остановиться.


Этот алгоритм отличается от алгоритма метода Флетчера – Ривса только вычислением параметра  $\beta$  на шаге 4.

# Метод Полака-Рибьера



Polak-Ribiere Method - 3D




Polak-Ribiere Method - 3D




Polak-Ribiere Method - 3D



$x_0 = (3, 3)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 3$   
 $x^* = (1.0, 8.0)$



$x_0 = (-1, 10)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 3$   
 $x^* = (8.0, 8.0)$



$x_0 = (-10, -3)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 3$   
 $x^* = (14.0, 8.0)$

# Метод Ньютона-Рафсона

## Алгоритм

*Шаг 1.* Задать  $x^0$ ,  $\varepsilon_1 > 0$ ,  $\varepsilon_2 > 0$ ,  $M$  – предельное число итераций. Найти градиент  $\nabla f(x)$  и матрицу Гессе  $H(x)$ .

*Шаг 2.* Положить  $k = 0$ .

*Шаг 3.* Вычислить  $\nabla f(x^k)$ .

*Шаг 4.* Проверить выполнение условия  $\|\nabla f(x^k)\| \leq \varepsilon_1$ :

а) если неравенство выполнено, то расчет закончен и  $x^* = x^k$ ;

б) если нет, перейти к шагу 5.

*Шаг 5.* Проверить выполнение условия  $k \geq M$ :

а) если неравенство выполнено, расчет окончен и  $x^* = x^k$ ;

б) если нет, перейти к шагу 6.

*Шаг 6.* Вычислить элементы матрицы  $H(x^k)$ .

# Метод Ньютона-Рафсона

*Шаг 7.* Найти обратную матрицу  $H^{-1}(x^k)$ .

*Шаг 8.* Проверить выполнение условия  $H^{-1}(x^k) > 0$ :

а) если условие выполняется, то найти  $d^k = -H^{-1}(x^k) \nabla f(x^k)$ ;

б) если нет, то положить  $d^k = -\nabla f(x^k)$ .

*Шаг 9.* Определить  $x^{k+1} = x^k + t_k d^k$ .

*Шаг 10.* Найти шаг  $t_k^*$  из условия  $\varphi(t_k) = f(x^k + t_k d^k) \rightarrow \min_{t_k}$ .

*Шаг 11.* Вычислить  $x^{k+1} = x^k + t_k^* d^k$ .

*Шаг 12.* Проверить выполнение неравенств

$$\|x^{k+1} - x^k\| < \varepsilon_2, \quad \left| f(x^{k+1}) - f(x^k) \right| < \varepsilon_2:$$

а) если оба условия выполнены при текущем значении  $k$  и  $k = k - 1$ , то расчет окончен и  $x^* = x^{k+1}$ ;


б) в противном случае положить  $k = k + 1$  и перейти к шагу 3.

# Основная функция метода Ньютона-Рафсона


```
def newton_raphson_sympy(f, x0, tol=1e-5, max_iter=1000):
    x1, x2 = sp.symbols('x1 x2')
    grad_f = gradient_sympy(f, (x1, x2))
    hess_f = hessian_sympy(f, (x1, x2))
    x_val = np.array(x0, dtype=float)
    path = [x_val.copy()]
    for i in range(max_iter):
        grad_val = np.array(grad_f(*x_val))
        hess_val = np.array(hess_f(*x_val))
        try:
            hess_inv = np.linalg.inv(hess_val)
        except np.linalg.LinAlgError:
            print(f"Newton-Raphson: Матрица Гессе вырождена в итерации {i + 1}")
            break
        x_new = x_val - hess_inv.dot(grad_val)
        path.append(x_new.copy())
        if np.linalg.norm(x_new - x_val) < tol:
            print(f"Newton-Raphson: Минимум найден в точке {x_new} за {i + 1} итераций")
            break
        x_val = x_new
    return x_val, np.array(path)
```

# Метод Ньютона-Рафсона


Newton-Raphson Method - 3D




Newton-Raphson Method - 3D



Newton-Raphson Method - 3D




Newton-Raphson Method - 2D




$x_0 = (1, 1)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 2$   
 $x^* = (1.0, 8.0)$

Newton-Raphson Method - 2D



$x_0 = (0, 0)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 2$   
 $x^* = (8.0, 8.0)$

Newton-Raphson Method - 2D



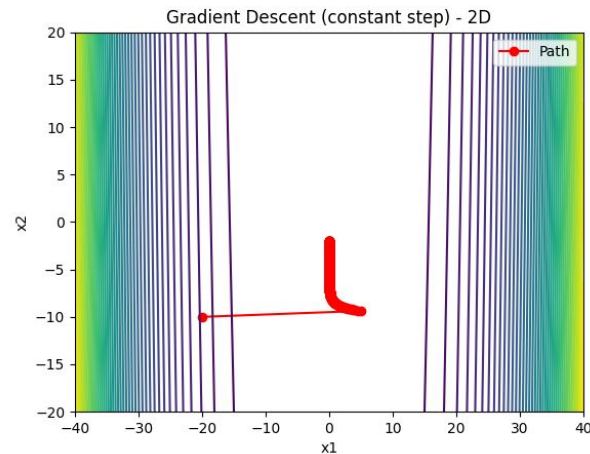
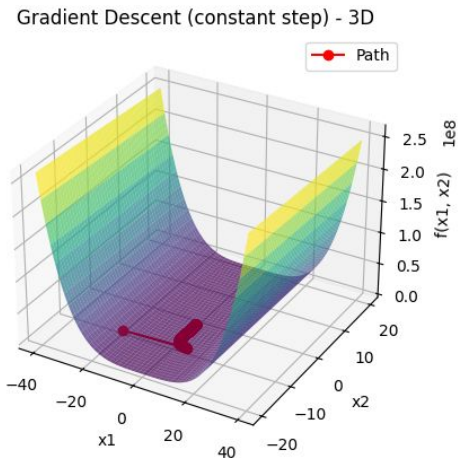
$x_0 = (19, -10)$   
 $\text{eps} = 1e5$   
 $\text{iter} = 2$   
 $x^* = (14.0, 8.0)$

# Функция Розенброка

$$f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

Метод градиентного спуска:

$x_0 = (-20, -10)$   
 $\text{eps} = 1e2$   
 $\text{iter} = 105$   
 $x^* = (0.98, 0.97)$





# Функция Розенброка

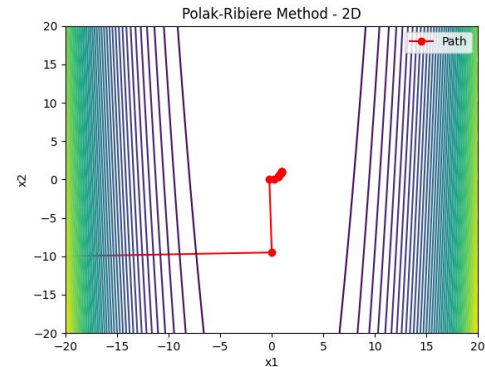
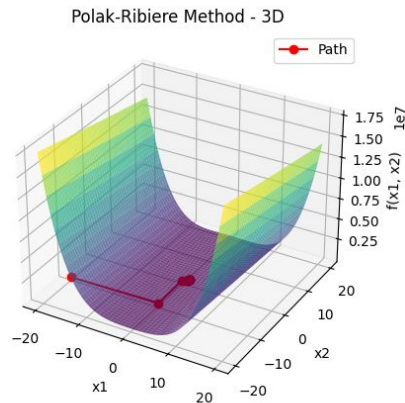
## Метод Полака-Рибьера:

$x_0 = (-20, -10)$

$\text{eps} = 1e5$

$\text{iter} = 14$

$x^* = (0.99999988,$   
 $0.99999976)$



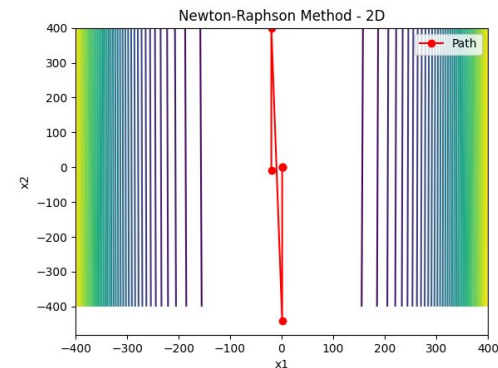
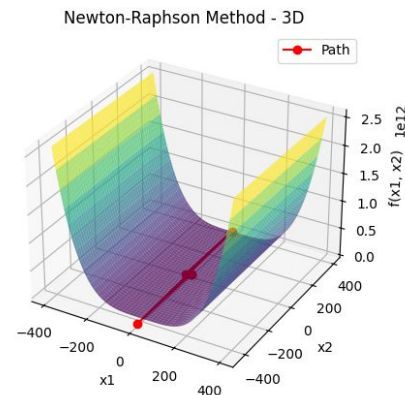
## Метод Ньютона-Рафсона:

$x_0 = (-20, -10)$

$\text{eps} = 1e5$

$\text{iter} = 5$

$x^* = (1.0, 1.0)$





# Выводы

- На функции Розенброка метод Ньютона-Рафсона показал наибольшую точность и эффективность, нашел точку минимума за наименьшее количество итераций, так как это метод второго порядка;
- Метод градиентного спуска с постоянным шагом показал сильную зависимость от выбора начального приближения и работает дольше всех;
- Метод Полака-Рибьера показал себя как очень устойчивый метод и имеет зависимость от формы и вида функции;